## 인공지능 기술 현황

2018. 1. 15. 유성준 세종대학교 인공지능-빅데이터연구센터 센터장 세종대학교 컴퓨터공학과 교수 sjyoo@sejong.ac.kr





http://www.abrc.or.kr

# 발표순서

- Ⅱ 인공지능의 역사, 한계, 비전
- Ⅲ 머신러닝 개념 소개
- III 딥러닝
- Ⅳ 딥러닝을 위한 컴퓨팅 구조
- V 결어

# Ⅱ 인공지능의 역사, 한계, 비전

### 인공지능은 만능?





#### False Promises - 1958



#### NEW NAVY DEVICE LEARNS BY DOING; Psychologist Shows Embryo of Computer Designed to Read and Grow Wiser

SPECIAL TO THE NEW YORK TIMES JULY 8, 1958










WASHINGTON, July 7 (UPI) -- The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself and be conscious of its existence.

"The Navy revealed the embryo of an electronic computer today that it expects will be able to walk, talk, see, write, reproduce itself an be conscious of its existence ... Dr. Frank Rosenblatt, a research psychologist at the Cornell Aeronautical Laboratory, Buffalo, said Perceptrons might be fired to the planets as mechanical space explorers" July 08, 1958

























## 인공지능에서 풀어야할 문제들








# Ⅲ 머신러닝 개념 소개

# 머신러닝을 사용하지 않고 사진 설명으로 강아지 인식하기

If then else 규칙을 이용한 접근 방법



### 머신러닝의 필요성




- Limitations of explicit programming
  - Spam filter: many rules
  - Automatic driving: too many rules
- Machine learning: "Field of study that gives computers the ability to learn without being explicitly programmed" Arthur Samuel (1959)





Supervised Learning : Learning with labeled examples – training set 이 필요



<출처> http://cs231n.github.io/classification/





y (grade)

Α

D

F

- Predicting final exam score based on time spent
  - regression
- Pass/non-pass based on time spent
  - binary classification
- Letter grade (A, B, C, D and F) based on time spent
  - multi-label classification

x (hours)	y (score)
10	90
9	80
3	50
2	30

x (hours)	y (pass/fail)
10	Р
9	Р
3	F
2	F

9 3 2

x (hours)

10

Regression 예

binary classification 예

Multi-label Classification 예

<예제 출처> 홍콩과기대 김성훈 교수 딥러닝 강의 노트



### Training Set = Big Data


Machine Learning = Data Driven Approach

#### AlphaGo:

- 전세계의 모든 기보를 훈련데이터로 활용
- 기존 접근 방법: 규칙 -> 한계


# 머신러닝을 이용하여 사진으로 강아지 인식하기












## 인공지능: 머신러닝 또는 딥러닝 등의 도구를 이용하여 인간 지응을 흉내낸 결과물




[=]

6



### 딥러닝 기본 구조





<출처> Why are GPUs necessary for training Deep Learning models? https://www.analyticsvidhya.com/blog/2017/05/gpus-necessary-for-deep-learning/

### 딥러닝기본 연산 = Matrix Multiplication



$$\begin{bmatrix} 7 & 8 \\ 9 & 10 \\ 11 & 12 \end{bmatrix}$$


$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 58 \\ 1 & 11 \end{bmatrix}$$

$$1 \cdot 7 + 2 \cdot 9 + 3 \cdot 11 = 58$$

## 딥러닝 연산구조







<출처> Why are GPUs necessary for training Deep Learning models? https://www.analyticsvidhya.com/blog/2017/05/gpus-necessary-for-deep-learning/

# IV 딥러닝을 위한 컴퓨팅 구조

### 인공지능을 위한 컴퓨팅 기술






	Google	Stanford
Number of cores	1K CPUs = 16K cores	3GPUs = 18K cores
Cost	\$5B	\$33K
Training time	week	week

Before the boom of Deep learning, Google had a extremely powerful system to do their processing, which they had specially built for training huge nets. This system was monstrous and was of \$5 billion total cost, with multiple clusters of CPUs.

Now researchers at Stanford built the same system in terms of computation to train their deep nets using GPU. And guess what; they reduced the costs to just \$33K! This system was built using GPUs, and it gave the same processing power as Google's system. Pretty impressive right?

## CRAY Announces New, Al-Focused Supercomputers




<출처> https://www.extremetech.com/computing/249149-cray-announces-new-ai-focused-supercomputers

### TSUBAME3.0

Tokyo Institute of Technology (Tokyo Tech) announced its plans for the TSUBAME3.0 supercomputer, which will be Japan's "fastest AI supercomputer," when it comes online this summer (2017).

Projections are that it will deliver 12.2 double-precision petaflops and 64.3 half-precision (peak specs)

We know that Nvidia will be supplying Pascal P100 GPUs



<출처> https://www.extremetech.com/computing/249149-cray-announces-new-ai-focused-supercomputers

## 외국기업 현황



기업/기관/국가	기술 동향	출처
IBM	<ul> <li>Watson 슈퍼 컴퓨터는 80 teraflops의 속도로 처리</li> <li>Watson은 2 억 페이지가 넘는 결합 된 데이터 저장소로 90 개의 서버 액세스</li> <li>600 만 가지 논리 규칙을 처리</li> <li>장치와 그 데이터는 10 개의 냉장고를 수용 할 수 있는 공간에 독립적으로 보관됨</li> <li>2,880 processor cores</li> <li>15 terabytes of RAM</li> <li>500 gigabytes of preprocessed information</li> </ul>	Margaret Rouse, "IBM Watson supercomputer," Whatis.com
	<ul> <li>자사에서 개발한 "트루노스 신경시냅틱 시스템 "을 기반으로 인공지능 시스템 개발중</li> <li>프로세서 자체가 인간의 신경세포와 시냅스 구조를 모방</li> </ul>	생탐, " 인공지능 연구한계점 도달, 해결법과 앞으로의 미래는?", 네이버포스트, 2017. 7. 11

# 외국기업현황



기업/기관/국가	기술 동향	출처
Cray	<ul> <li>AI를 지원하기 위한 슈퍼컴퓨터 발표</li> <li>Cray CS-Storm 500GT 및 CS-Storm 500NX</li> <li>두 제품 모두 Nvidia의 Pascal 기반 Tesla GPU와 작동하도록 설계되었지만 서로 다른 기능 세트 및 기능을 제공</li> <li>CS-Storm 500GT는 Nvidia의 Tesla P40 또는 P100 GPU 가속기를 포함하여 최대 8 x 450W 또는 10 x 400W 가속기를 지원</li> </ul>	Joel Hruska, "Cray Announces New, Al- Focused Supercomputers," ExtrmeTech, May 11, 2017
마이크로 소프트	<ul> <li>클라우드 기반 데이터 센터에 강력한 실리콘 FPGA 설치</li> <li>급성장하는 인공 지능 분야에서 마이크로소프트사의 Azure 인공지능 컴퓨팅 플랫폼이 강력한 경쟁 우위를 확보하고자하는 목표 추구</li> </ul>	Dan Richman, "Microsoft demonstrates the world's 'first AI supercomputer,' using programmable hardware in the cloud," September 26, 2016, GeekWire

# CRAY Announces New, Al-Focused Supercomputers

		CS-Storm 500GT	CS-Storm 500NX
	Processors	Two Intel® Xeon® "Skylake" family processors	Intel Xeon E5-2600 v4 family processors
	Memory Capacity	Up to 2 TB DDR4 (16 x 128 GB DIMMs)	Up to 3 TB DDR4 (24 x 128 GB DIMMs)
Г	Accelerators	Up to 10 NVIDIA* Tesla* P40 or P100 PCIe GPU accelerators; supports up to 400W parts	Up to 8 NVIDIATesla P100 SXM2 GPU accelerators; supports up to 300W parts
	Drive Bays	Multiple local storage configuration options. 12 hot-swappable 2.5" drives (up to 4 x NVMe). Some configurations require an additional add-in storage controller; total number of drives varies by configuration.	16 hot-swappable 2.5" drives (up to 8x NVMe)
	Expansion Slots	12 PCle 3.0 x 16 slots supporting multiple PCle topologies and configuration options	4 x16, low-profile (GPU tray), 2 x 8 (motherboard tray) PCIe 3.0
	Power Supply	Four 2200W AC power supplies; N+1 and N+N (limited to specific configurations) redundancy	Four 2200W AC power supplies; 2+2 redundancy; titanium-level efficiency
	Power Input	200-277VAC, 10A max	200-277VAC, 10A max
	Weight	Up to 76 lbs. (without PCIe cards)	Up to 135 lbs.
	Dimensions	5.25" H x 17.6" W x 36.4"D (3U)	7.0"H x 17.6"W x 29"D (4U)
	Temperature	Operating: 10°C-35°C, ASHRAE 2	Operating: 10°C-35°C, ASHRAE 2

<출처> https://www.extremetech.com/computing/249149-cray-announces-new-ai-focused-supercomputers

## 외국기업현황

	···(∰)···.
	//*.

기업/기관/국가	기술 동향	출처
구글	<ul> <li>TPU 포드 (Pods)라고 불리는 64 개의 TPU를 통합하여 11.5 페타 플롭의 연산 능력을 갖춘 슈퍼 컴퓨터로 효과적으로 전환 할 수있는 방법을 개발</li> <li>2세대 TPU는 180 teraflops의 컴퓨팅 파워 제공 목표</li> <li>알파고는 1 petaflops 정도의 계산속도 소요</li> </ul>	Nick Statt, "Google's next-generation Al training system is monstrously fast," May 17, 2017, THEVERGE
	• Ray KuzWeil 기술 이사를 필두로 양자컴퓨터 개발중 – 양자컴퓨터와 딥러닝 및 머신러닝 접목중	생탐, " 인공지능 연구한계점 도달, 해결법과 앞으로의 미래는?", 네이버포스트, 2017. 7. 11
일본	<ul> <li>AI 브리징 클라우드 컴퓨터 (AIBC)를 만들기 위해 195 억엔 (140 백만 파운드) 예산 투입 계획</li> <li>130 petaflops의 속도 목표</li> </ul>	"Japan kicks off Al supercomputer project," 28 November 2016, BBC.com

## AlphaGo 구성 및 원가(?)



#### 알파고 2년간 운영 비용(최대)



항목	스펙		총비용
1. 개발자	20명 (연봉) 3억6000만원/인당		
2. 프로젝트 기간	2년		
3. 투입리소스	100MM		30억원
4. 인프라 비용	인프라	CPU 1920개, GPU 280개 (분산서버 시간당 운영 비용) 282.8\$	58억2000만원
	CPU(가격/시)	c3.8xlarge*60대 = CPU(1920개)*1.68\$(가격/시)=100.8\$	
	GPU(가격/시)	g2.8xlarge*70대 = GPU(280개)*2.6\$(가격/시) =182\$	
합계			88억2000만원

<그래픽=홍종현 미술기자>

### 일본



AI R&D 협력 센터(AI Bridging Cloud Infrastructure)

ABCI: World's first and

largest open 100 Peta Al-Flops Al Supercomputer, Fall 2017, for co-design

### Co-Design of BD/ML/AI with HPC using BD/ML/AI

- for survival of HPC

Accelerating Conventional HPC Apps



Optimizing System Software and Ops



Future Big Data · AI Supercomputer Design




Acceleration and Scaling of BD/ML/Al via HPC and Technologies and Infrastructures

Big Data Al-Mutual and Semi-Oriented Automated Co-Acceleration of Supercomput HPC and BD/ML/AI ers

> Acceleration Scaling, and Control of HPC via BD/ML/Al and future SC designs

Big Data and ML/Al Apps and Methodologies

Large Scale Graphs





Robots / Drones





### 딥러닝을 위한 처리 속도 요구사항



P:Peta

E:Exa

F:Flops



Estimated Compute Resource Requirements for Deep Learning [Source: Preferred Network Japan Inc.]

To complete the learning phase in one day

Image/Video Recognition



10P (Image) ~ 10E (Video) 学習データ:1億枚の画像 10000クラス分類

数千ノードで6ヶ月 [Google 2015]

**Image Recognition** 

Bio / Healthcare



100P ~ 1E Flops

一人あたりゲノム解析で約10M個のSNPs 100万人で100PFlops、1億人で1EFlops

**Auto Driving** 







1万人の5000時間分の音声データ 人工的に生成された10万時間の 音声データを基に学習 [Baidu 2015]



1E~100E Flops 自動運転車1台あたり1日 1TB

10台~1000台, 100日分の走行データの学習



1E~100E Flops

1台あたり年間1TB 100万台~1億台から得られた データで学習する場合

機械学習、深層学習は学習データが大きいほど高精度になる 現在は人が生み出したデータが対象だが、今後は機械が生み出すデータが対象とな

各種推定値は1GBの学習データに対して1日で学習するためには 1TFlops必要だとして計算

1EF 10EF 100PF 100EF 10PF 2015 2020 2025 2030

So both are important in the infrastructure

It's the FLOPS

(in reduced

precision)

and BW!

〈출처〉最新のHPC技術を生かしたAI・ビッグデータ, 2017, NVIDIA Deep Learning Institute Day



# 인공지능시스템 수행에 필요한계산등력

- **IBM Watson: 80TFlops**
- Alphago: 1PFlops
- Chatbot: 그 이하
- 인간의 영상 인식과 동일한 수준의 인식이 가 능하려면?
- 인간의 언어 통역과 인식 수준의 인식이 가능 하려면?

### 시사점 및 추진 방향



- 현재는 알고리즘에 의한 빅데이터 처리 를 통해 인공지능 시스템이 동작 발전
- 향후 하드웨어적으로도 신기술 등장 예 상

### 감사합니다 Q&A



